



UNIVERSITATEA TEHNICĂ

DIN CLUJ-NAPOCA

FACULTATEA DE AUTOMATICĂ ȘI CALCULATOARE
DEPARTAMENTUL CALCULATOARE

SINTEZA

proiectului de diplomă cu titlul:

**IMPLEMENTAREA SI ANALIZA METODELOR DE INVATARE PROFUNDA
PE DISPOZITIVE INTEGRATE CU RESURSE LIMITATE**

Autor: **Andreea-Valentina ANASTASIU**
Coordonator: **S.I. Dr. Ing. Mircea Paul MURESAN**

1. Cerințele temei:

Aceasta tema propune realizarea implementarilor, dar si analiza comparative intre 4 metode diferite de implementare a inferentei pentru un model neuronal convolutional (CNN) pe placa Zybo Z7-20, care are un processor ARM Cortex-A9 si FPGA. Pentru a asigura o evaluare obiectiva, se utilizeaza acelasi suport fizic, aceleasi aproximativ acelasi ponderi (metoda FINN le genereaza singur) ale modelului si acelasi set de date de intrare pentru toate arhitecturile.

2. Soluții alese:

Arhitectura modelului CNN ales, Convolutie 2D (16 filtre, 3x3) -> subesantionare prin maxim (2x2) -> strat complet conectat (32 neuroni) -> strat complet conectat (10 neuroni) -> determinarea indicelui valorii maxime. Au fost dezvoltate si evaluate 5 implementari. Prima dintre ele, in Python, a presupus antrenarea modelului si exportul ponderilor in format cu virgula mobila pe 32 de biti. A doua este implementarea in VHDL, care reprezinta un accelerator hardware dezvoltat in logica programabila, unde fiecare strat al rețelei a fost descris ca un modul, iar comunicarea se realizeaza prin magistrala AXI si memoria interna BRAM, conform Figurii 1. Cea de a treia abordare utilizeaza FINN, cu un model definit in PyTorch/Brevitas si o cuantizare a valorilor pe 8 biti, compilat cu FINN rezultand un accelerator hardware; comunicarea este cu AXI DMA. In final s-au realizat 2 variante software: o implementare C scalar, care reprezinta varinata de referinta executata strict secvential pe procesorul ARM si o implementare ARM NEON, care prelucreaza acelasi flux de date utilizand instructiuni vectoriale.

3. Rezultate obținute:

Toate implementarile au fost evaluate pe acelasi set de imagini augmentate. Rezultatele sunt evidentiate in tabelul 1, iar imagini cu un rezultat este reprezentat in Figura 2.

Tabelul 1. Rezultate comparative

Implementare	Imagini corecte/1000	Acuratete	Timp mediu /img	Resurse fizice
FINN	714	71.40%	2.75 ms	23077LUT, ~47 BRAM
VHDL	822	82.20%	31 ms	15304 LUT, 135 BRAM
C SCALAR	822	82.20%	249 ms	-
ARM NEON	822	82.20%	292 ms	-

4. Testări și verificări:

- Timpul de execuție a fost măsurat cu număratorul de cicluri al procesorului, oferind o precizie la nivel de ciclu de ceas
- A fost confirmată identitatea numerică a rezultatelor între VHDL, C scalar și NEON.
- S-a remarcat un rezultat arhitectural atipic: implementarea ARM NEON a fost mai lentă ca cea scalară în C, ceea ce evindetiaza limitările unui procesor cu execuție secvențială.

5. Contribuții personale:

- Antrenarea modelului CNN în Python cu augmentare și exportul ponderilor pentru implementări
- Proiectare integrală, a modulelor în VHDL, a implementării vectorizate NEON și a celei în C scalar, dar și dezvoltarea aplicației care le orcheștează
- Configurarea și integrarea framework-ului FINN

6. Surse de documentare:

[1] T. Li and S. Gu, "An FPGA-based Convolutional Neural Network Accelerator for Edge Computing," 2024 9th International Conference on Robotics and Automation Engineering (ICRAE), Singapore, Singapore, 2024, pp. 211-216, doi: 10.1109/ICRAE64368.2024.10851511.

[2] M. . Blott, T. B. Preußner, N. J. Fraser, G. Gambardella, K. O'Brien, Y. Umuroglu, M. Leeser and K. Vissers, "FINN-R: An End-to-End DeepLearning Framework for Fast Exploration of Quantized Neural Networks," ACM Trans. Reconfigurable Technol. Syst., vol. 11, no. 3, 2018. doi: 10.1145/3242897




Figura 1



Figura 2